

Expertenwissen aus MP zurück ins Wissensnetz

Expert Knowledge Transfer: von der Selektion zum RDF-Tripel

Projekt DataBridge · 26ss_CB_DataBridge · Teilbereich Wissensnetz (Marcel Thiel)

Status: **Entwurf v0.1** · Stand: 20.08.2026

Dieses Dokument ist das Gegenstück zum Mapping-Konzept. Während das Mapping Daten in das Wissensnetz *hineinbringt*, erfasst der Rückkanal das Wissen, das beim explorativen Arbeiten mit Morphing Projections (MP) entsteht, und schreibt es *zurück*. Theoretischer Rahmen ist das Wissensgenerierungs-Modell für Visual Analytics (Sacha et al., aufbauend auf van Wijk): Der Erkenntnisgewinn entsteht im Kreislauf aus Interaktion und Sicht – genau diesen Kreislauf soll DataBridge schließen. Das Dokument führt die möglichen Methoden auf und gibt eine Empfehlung für den Prototyp.

1 Ausgangslage: Interaktion in MP

MP bietet dem Arzt drei Interaktions-Primitive: Proben nach einem Attribut räumlich **anordnen**, per Slider zwischen Sichten **morphen**, und Probengruppen **selektieren**, die über verschiedene Sichten hinweg erhalten bleiben. Erkennt der Experte dabei ein Muster (etwa das gemeinsame Driften der sechs fehlklassifizierten PAAD-Proben aus Fallstudie 1 des Papers), entsteht wertvolles, aber *implizites* Wissen – das heute nach dem Schließen des Browsers verloren ist. Der Rückkanal macht es persistent und maschinenlesbar.

2 Was genau erfassen? Anatomie einer Entdeckung

Eine „Entdeckung“ ist keine einzelne Zahl, sondern ein strukturiertes Ereignis. Diese Facetten muss der Rückkanal festhalten:

Facette	Bedeutung	Beispiel (Fallstudie 1)
Subjekt (wer)	Urheber der Erkenntnis	Experte / Nutzer
Objekt (was)	selektierte Probenmenge	6 PAAD-Proben
Aussage (warum)	Hypothese / neue Relation	„eigentlich PanNET, nicht PAAD“
Kontext	Sichten + Morph-Parameter t	Gen-tSNE ↔ miRNA-tSNE
Konfidenz	subjektive Sicherheit	hoch / 0.7
Zeit	Zeitstempel	2026-08-20

3 Der Rückkanal im Überblick



Abb. 1: Vom Interaktions-Ereignis zum Tripel. Die Erkenntnis wird erfasst, nach RDF übersetzt (mit RDF-star-Provenienz) und via SPARQL Update geschrieben; künftig reichert sie die Anordnung/Navigation wieder an.

4 Mögliche Methoden

Der Rückkanal lässt sich entlang von vier Entscheidungsachsen zusammensetzen. Pro Achse die Optionen mit kurzer Einordnung.

4.1 Erfassen der Interaktion (Capture)

- **REST-Event-Endpoint am Mediator.** Das Frontend sendet bei einer Selektion ein JSON-Event. Sauber entkoppelt, erfordert aber eine kleine Anpassung der Oviedo-Tools.
- **Explizite Annotations-UI.** Der Arzt bestätigt/benennt eine Erkenntnis aktiv (Tag, Notiz). Höhere Datenqualität, weniger Rauschen – aber Zusatzaufwand für den Nutzer.
- **Interaktions-Log / Event-Stream.** Das Tool protokolliert Interaktionen, der Mediator wertet sie aus. Kein UI-Eingriff, aber viel Rauschen und schwierige Intentionserkennung.

4.2 Modellierung in RDF (wie die Annotation aussieht)

- **RDF-star.** Provenienz und Konfidenz direkt an der Kern-Aussage (<< ... >>). Schlank und konform zu ADR-0002.
- **Named Graph pro Sitzung/Nutzer.** Jede Erkenntnis landet in einem benannten Graphen – leicht zu isolieren, zu versionieren und zu widerrufen.
- **PROV-O + Web Annotation Data Model (oa).** W3C-Standards für Provenienz bzw. Annotationen – interoperabel und ausdrucksstark, aber etwas verbosier.
- **Nanopublications.** Etabliertes biomedizinisches Muster (Assertion + Provenienz + Publikationsinfo als RDF). Zitierfähig, aber schwergewichtig für einen Prototyp.

4.3 Schreib-Mechanismus (Write)

- **SPARQL Update (INSERT DATA).** W3C-Standard, direkt von Jena/Fuseki unterstützt – der pragmatische Default.
- **SNQL-artiges Protokoll (Stadler).** Konzeptioneller Bezug aus deinen Quellen: dynamische Graph-Manipulation zur Laufzeit (insert/update/copy relation). Für den Bericht als theoretischer Rahmen, praktisch auf SPARQL Update abbildbar.
- **Graph Store HTTP Protocol.** REST-artiges Schreiben ganzer Graphen – praktisch in Kombination mit Named Graphs pro Sitzung.

4.4 Ablage / Trennung (Where)

- **Getrenntes persönliches Wissensnetz.** Nutzer-Erkenntnisse als eigene ABox/Named Graphs; die Kern-TBox (Schema) bleibt stabil und unverfälscht. Empfohlen.
- **Gemeinsames Netz mit Kuratierung.** Erkenntnisse fließen erst nach einem Review ins geteilte Netz – höhere Vertrauenswürdigkeit, mehr Prozess.

5 Vergleich & Empfehlung

RDF-Modellierung	Stärke	Schwäche	Prototyp
RDF-star	Provenienz an der Aussage, schlank	Standard noch jung (RDF 1.2 CR)	Ja (Kern)
Named Graph / Sitzung	Isolation, widerrufbar	Provenienz separat	Ja (Ablage)
PROV-O + oa:Annotation	W3C-Standard, interoperabel	verbosier	teilweise
Nanopublications	biomed-Referenz, zitierfähig	schwergewichtig	später

Empfehlung für den Prototyp: REST-Event-Endpoint (4.1) → Modellierung als oa:Annotation mit PROV-O-Metadaten und RDF-star für die Kern-Aussage (4.2), abgelegt in einem Named Graph pro Nutzer/Sitzung (4.4), geschrieben per SPARQL Update (4.3) – konzeptionell als SNQL-Protokoll gerahmt. Das nutzt W3C-Standards, bleibt schlank und hält die Kern-TBox sauber getrennt.

6 Konkretes Beispiel: PAAD → PanNET (Fallstudie 1)

Der Arzt selektiert die sechs gemeinsam driftenden Proben und markiert sie als mögliche Fehlklassifikation. Daraus entsteht:

```
@prefix db: <http://databridge.hka/onto#> .
@prefix oa: <http://www.w3.org/ns/oa#> .
@prefix prov: <http://www.w3.org/ns/prov#> .
@prefix rdfs: <http://www.w3.org/2000/01/rdf-schema#> .
@prefix xsd: <http://www.w3.org/2001/XMLSchema#> .

db:anno-0421 a oa:Annotation , db:ExpertFinding ;
  prov:wasAttributedTo db:user-nvaldes ;
  prov:generatedAtTime "2026-08-20T14:12:00"^^xsd:dateTime ;
  db:inView "gene-tSNE <-> miRNA-tSNE" ;
  db:morphParam 1.0 ;
  db:confidence "hoch" ;
  oa:hasTarget ( db:sample-TCGA-2J-AAB1
    db:sample-TCGA-3A-AAL5
    db:sample-TCGA-HZ-A4BH ) ; # 6 Proben (gekürzt)
  db:hypothesis [ a db:Reclassification ;
    db:from ncit:PAAD ; db:to ncit:PanNET ;
    rdfs:comment "Common fate: driften gemeinsam zum PCPG-Cluster" ] .

# RDF-star: Konfidenz/Provenienz direkt an der Kern-Aussage
<< db:sample-TCGA-2J-AAB1 db:reclassifiedAs ncit:PanNET >>
  prov:wasDerivedFrom db:anno-0421 ;
  db:confidence 0.7 .
```

Kernidee: Die Geste des Arztes wird zu einer nachvollziehbaren, widerrufbaren Aussage – mit Urheber, Sicht, Zeitpunkt und Konfidenz. So lernt das Wissensnetz aus der Analyse, ohne dass ungeprüfte Fakten die Kern-Ontologie verunreinigen.

7 Offene Punkte & nächste Schritte

- **Abstimmung mit Oviedo:** Kann MP ein Selektions-Event senden (kleiner Frontend-Eingriff), oder wird der Rückkanal zunächst mit simulierten Events prototypisch gezeigt?
- **Vokabular festlegen:** eigene Properties (db:ExpertFinding, db:hypothesis, db:reclassifiedAs) definieren und wo sinnvoll auf oa/PROV-O abbilden.
- **Vertrauens-/Review-Modell:** bleiben Erkenntnisse „privat“ oder gibt es einen Weg ins geteilte Netz (Kuratierung)?
- **Proof-of-Concept:** ein simuliertes Selektions-Event → Turtle → per SPARQL Update in einen Named Graph in Fuseki schreiben und zurückabfragen.

8 Quellen

- [Sacha et al. – Knowledge Generation Model for Visual Analytics \(2014\)](#)
- [Díaz et al. – Morphing projections \(Bioinformatics 2021\)](#)
- [W3C – PROV-O: The PROV Ontology](#)
- [W3C – Web Annotation Data Model \(oa\)](#)
- [W3C – SPARQL 1.2 \(Update, RDF-star\)](#)
- [Nanopublications – Konzept & Guidelines](#)
- wissensnetz/Mapping-Konzept_GDC-zu-RDF-OWL.docx – Gegenstück (Daten hinein)
- docs/adr/0002-graph-db-wahl-offen.md – RDF/OWL + RDF-star